

MCDI504

MACHINE LEARNING I

**AVANCE DEL PROYECTO — FASE 1:
DEFINICIÓN Y ORIENTACIÓN DE LA
SITUACIÓN**

Nombre integrante/s:

Fabian Castillo

Francisco Santelices

Renato Villazón

**Curso: MCDI 504 –
Machine Learning I**

Fecha: 09 Julio 2026

Índice

I. Introducción y contextualización	3
II. Definición de la problemática y objetivos del proyecto	3
2.1 Formulación del problema	3
2.2 Pregunta analítica	4
2.3 Objetivo general	4
2.4 Objetivos específicos	4
2.5 Tipo de datos considerados y alcance	4
2.6 Relación entre el problema definido y el proceso KDD	5
III. Clasificación del tipo de aprendizaje	5
3.1 Tipo de aprendizaje seleccionado	5
3.2 Relación entre datos, objetivo y aprendizaje	5
3.3 Análisis y Descarte de Paradigmas Alternativos	6
IV. Relación entre Machine Learning y metodología KDD	6
4.1 Selección de los datos	6
4.2 Preprocesamiento de datos	7
4.3 Transformación de los datos	7
4.4 Minería de datos y modelamiento	7
4.5 Interpretación y evaluación	8
4.6 Síntesis del flujo KDD	8
V. Notebook F1_Definición.ipynb	8
5.1 Definición del problema en el notebook	9
5.2 Objetivo representados en el notebook	9
5.3 Estructura del flujo de trabajo	9
5.4 Descripción del código base	10
5.5 Evidencias técnicas obtenidas	11
5.6 Correspondencia entre el notebook y el enfoque seleccionado	11
5.7 Decisiones y limitaciones del notebook	12
5.8 Síntesis del notebook	12
VI. Comparación de enfoques y justificación del descarte	13
6.1 Enfoque seleccionado: clasificación supervisada multiclase	13
6.2 Alternativa 1: regresión supervisada	14
6.3 Alternativa 2: aprendizaje no supervisado	14
6.4 Alternativa 3: aprendizaje por refuerzo	14
6.5 Comparación de los enfoques	15
6.6 Justificación de la decisión adoptada	15
VII. Documentación del proceso	16
7.1 Decisiones técnicas	16
7.2 Relación entre decisiones y enfoque	16
VIII. Conclusiones	16
8.1 Síntesis de decisiones	16
8.2 Relación con KDD	17
8.3 Proyección del enfoque	17
IX. Uso de fuentes, citación y referencias	17
X. Anexos	18

APARTADOS

I. Introducción y contextualización

Este avance de la Fase 1, tiene como propósito definir el problema analítico, caracterizar los datos disponibles y seleccionar el enfoque de aprendizaje más pertinente, estableciendo las bases conceptuales y metodológicas del proyecto, sin incluir aún el entrenamiento de modelos predictivos (Ruete, 2026a; Ruete, 2026b).

El caso de estudio se centra en *IrisFlow*, una operación ficticia de recepción y empaque de flora ornamental, que busca clasificar flores de iris mediante características morfológicas cuantitativas, estableciendo una relación explícita entre la situación, los datos y el objetivo buscado (Ruete, 2026a). Para ello, se emplea el dataset Iris, introducido históricamente por Fisher (1936) como un antecedente relevante para el análisis estadístico multivariado y la discriminación entre grupos (Fisher, 1936).

El conjunto Iris, consta de 150 observaciones distribuidas equitativamente en 3 clases (50 por clase), 4 variables predictoras numéricas sobre las dimensiones de sépalos y pétalos, y una variable objetivo-categorica para la especie (Scikit-learn developers, s. f.). Al disponer de una variable objetivo etiquetada y conocida para predecir una categoría, el problema se fundamenta y aborda metodológicamente bajo un enfoque de aprendizaje supervisado de clasificación multiclase (Ruete, 2026a; Scikit-learn developers, s. f.).

Finalmente, la exploración inicial desarrollada en el notebook contempló la carga de datos, inspección de estructura, análisis descriptivo, visualizaciones, estudio de correlaciones y preparación de variables, respaldando con evidencia técnica las decisiones adoptadas en esta fase (Ruete, 2026c).

II. Definición de la problemática y objetivos del proyecto

2.1 Formulación del problema

En una operación de recepción y empaque de flora ornamental, la identificación correcta de las especies constituye una actividad necesaria para clasificar adecuadamente las flores. Cuando esta identificación depende exclusivamente de la observación de características morfológicas, pueden existir dificultades cuando las categorías presentan similitudes entre sí. Esta situación, puede transformarse en un problema analítico cuando se dispone de mediciones cuantitativas, que permitan representar las características de cada observación (Fisher, 1936).

En el caso IrisFlow, esta situación se representa mediante el dataset Iris, que contiene cuatro variables numéricas asociadas a las dimensiones del sépalo y del pétalo y una variable objetivo que identifica la especie correspondiente. La documentación oficial de scikit-learn confirma que el conjunto contiene 150 observaciones distribuidas en tres clases, con cuatro dimensiones de entrada (Scikit-learn developers, s. f.).

El problema de ciencia de datos consiste, por tanto, en determinar si las características morfológicas disponibles permiten fundamentar un enfoque de Machine Learning orientado a clasificar las flores Iris en tres especies conocidas.

Esta formulación permite pasar desde una situación contextual hacia un problema analítico definido mediante datos, variables de entrada, variable objetivo y propósito de predicción, siguiendo la estructura

metodológica propuesta para la Fase 1 (Ruete, 2026a).

En esta etapa no se busca determinar todavía qué algoritmo presenta el mejor desempeño ni realizar predicciones finales. El propósito consiste en establecer una definición analítica sólida del problema, caracterizar los datos disponibles y justificar el enfoque de aprendizaje que será utilizado en las fases posteriores (Ruete, 2026a; Ruete, 2026b).

2.2 Pregunta analítica

¿Las características morfológicas del dataset Iris, permiten diferenciar sus tres especies mediante un enfoque de aprendizaje supervisado?

2.3 Objetivo general

Determinar la pertinencia del aprendizaje supervisado para clasificar las especies de Iris, a partir de sus características morfológicas, mediante la exploración y preparación del conjunto de datos.

2.4 Objetivos específicos

- Caracterizar la estructura, variables y clases del dataset Iris.
- Describir estadísticamente las variables morfológicas y analizar su distribución.
- Explorar visualmente las diferencias entre las tres especies.
- Analizar las relaciones entre las variables predictoras.
- Verificar la calidad de los datos, incluyendo valores faltantes y tipos de variables.
- Preparar las variables para su utilización en las etapas posteriores de Machine Learning.
- Justificar la selección de clasificación supervisada en función de la variable objetivo y la estructura de los datos.
- Relacionar las actividades realizadas con las etapas iniciales de la metodología KDD (Fayyad et al., 1996).

2.5 Tipo de datos considerados y alcance

El análisis se limita al dataset Iris, compuesto por 150 observaciones correspondientes a tres especies: *setosa*, *versicolor* y *virginica*. Cada registro contiene cuatro características morfológicas: longitud y ancho del sépalo y longitud y ancho del pétalo (Scikit-learn developers, s. f.).

En esta fase, se utilizarán estas variables para explorar la estructura de los datos, identificar patrones entre las especies y determinar su pertinencia para una futura clasificación supervisada. El alcance no contempla el entrenamiento ni la evaluación de modelos, los cuales serán desarrollados en las siguientes fases.

Tabla 1 Caracterización de los datos y alcance de la Fase 1.

Componente	Descripción
Observaciones	150 flores
Variables predictoras	4 características morfológicas
Variable objetivo	Species
Categorías	<i>setosa, versicolor, virginica</i>
Tipo de problema	Clasificación multiclase
Alcance Fase 1	Exploración, caracterización y preparación de los datos
Fuera del alcance	Entrenamiento y evaluación de modelos

La delimitación permite mantener correspondencia entre la pregunta analítica, los datos disponibles y el enfoque de aprendizaje seleccionado, evitando anticipar resultados que serán obtenidos durante las fases posteriores.

2.6 Relación entre el problema definido y el proceso KDD

El problema de clasificación de especies Iris, se integra en la metodología KDD, un proceso general que abarca desde la preparación de datos hasta la generación de conocimiento útil (Fayyad et al., 1996).

En esta Fase 1, el trabajo se enfoca en la definición del problema, la selección del dataset y sus variables relevantes, el preprocesamiento mediante la revisión de su estructura y calidad, y la transformación requerida para adecuar los datos. De esta forma, se establecen las bases para desarrollar la minería de datos con algoritmos supervisados y la posterior interpretación y evaluación de los modelos en fases avanzadas del proyecto (Fayyad et al., 1996).

III. Clasificación del tipo de aprendizaje

3.1 Tipo de aprendizaje seleccionado

El enfoque seleccionado es Aprendizaje Supervisado de Clasificación Multiclase.

Se fundamenta en dos condiciones clave de los datos:

- Existe etiqueta conocida: Cada observación cuenta con la variable objetivo Species previamente identificada.
- La salida es categórica discreta: El resultado a predecir no es un número continuo, sino la pertenencia a una de tres clases distintas (*setosa, versicolor o virginica*).

3.2 Relación entre datos, objetivo y aprendizaje

La selección del enfoque, se deriva directamente de la estructura del dataset: las cuatro variables morfológicas de entrada representan los atributos continuos de la flor, mientras que la variable objetivo Species entrega una etiqueta previa con tres clases nominales (*setosa, versicolor, virginica*).

Esta correspondencia entre datos etiquetados y el propósito de asignar una categoría define la siguiente cadena lógica de decisión:

Datos etiquetados → Variable objetivo-categorica → Predicción de clase → Aprendizaje Supervisado de Clasificación Multiclase.

3.3 Análisis y Descarte de Paradigmas Alternativos

Para garantizar el rigor metodológico, se evaluaron enfoques analíticos alternativos:

- Aprendizaje No Supervisado (Clustering): Aunque aplicable para la detección de agrupamientos intrínsecos sin guías previas, resulta subóptimo al ignorar intencionalmente las etiquetas de supervisión disponibles en el dataset *Iris*.
- Regresión Supervisada: Descartada formalmente debido a que la variable *Species* carece de naturaleza métrica o continua; no se busca predecir una magnitud numérica sino una etiqueta de categoría.
- Aprendizaje por Refuerzo: Incompatible con la arquitectura estática de los datos, al no existir un entorno dinámico, interacción mediante agentes ni señales de recompensa secuencial.

IV. Relación entre Machine Learning y metodología KDD

La metodología Knowledge Discovery in Databases (KDD) organiza el proceso mediante el cual los datos se transforman en conocimiento útil. Este proceso comprende las etapas de selección, preprocesamiento, transformación, minería de datos e interpretación o evaluación. En el proyecto *IrisFlow*, Machine Learning se incorpora como parte de este proceso y no como una actividad aislada, debido a que la futura construcción de un modelo de clasificación depende de las decisiones adoptadas previamente sobre el problema, los datos y su preparación (Fayyad et al., 1996).

Durante esta Fase 1 no se entrenan ni evalúan modelos. El trabajo se concentra en definir el problema analítico, seleccionar los datos pertinentes, revisar su calidad y preparar las variables. Estas actividades permiten establecer una base coherente para aplicar posteriormente algoritmos de aprendizaje supervisado orientados a clasificar las flores en las especies *setosa*, *versicolor* y *virginica*.

4.1 Selección de los datos

En la etapa de selección se decidió utilizar el conjunto de datos *Iris*, debido a que su estructura representa el problema analítico definido para *IrisFlow*. Cada observación corresponde a una flor y contiene cuatro mediciones morfológicas que pueden emplearse como variables predictoras: longitud y ancho del sépalo, y longitud y ancho del pétalo.

También se seleccionó *Species* como variable objetivo, ya que identifica la especie conocida de cada observación. Esta decisión determina que el futuro modelo deberá aprender la relación existente entre las características morfológicas y una categoría previamente etiquetada. Por ello, la selección de los datos respalda el uso de aprendizaje supervisado de clasificación multiclase.

La evidencia técnica de esta etapa se encuentra en el notebook, específicamente en la carga del dataset mediante `load_iris()` y en la construcción del DataFrame `bbdd1`.

4.2 Preprocesamiento de datos

El preprocesamiento busca comprobar que los datos seleccionados posean condiciones adecuadas para el análisis. Para ello, en el notebook se revisaron la estructura del conjunto, los tipos de variables y las principales medidas descriptivas mediante `info()` y `describe()`.

Esta revisión permitió confirmar que el dataset contiene 150 observaciones, cuatro variables predictoras numéricas y una variable objetivo-categorica. Asimismo, se verificó que no existen valores faltantes y que las tres clases presentan 50 observaciones cada una.

Estas características son relevantes para la futura aplicación del modelo, porque reducen la necesidad de imputar datos y evitan, inicialmente, un desbalance entre las categorías. Por consiguiente, se decidió conservar las 150 observaciones y no aplicar procedimientos de eliminación o imputación en esta fase.

4.3 Transformación de los datos

En la etapa de transformación se prepararon representaciones de los datos apropiadas para distintos propósitos analíticos. Primero, se creó una copia denominada `bbdd2`, en la cual `Species` fue codificada temporalmente con valores numéricos para facilitar el cálculo exploratorio de correlaciones y p-valores.

Esta codificación se utilizó únicamente como recurso estadístico y no modifica la naturaleza de `Species`, que continúa siendo una variable categorica nominal. Por esta razón, sus valores numéricos no deben interpretarse como cantidades ni como una escala ordinal entre especies.

Adicionalmente, las cuatro variables predictoras fueron normalizadas mediante `MinMaxScaler`, llevándolas al intervalo entre 0 y 1. Se decidió aplicar esta transformación solamente a las variables de entrada y conservar `Species` en su formato categorico original. La normalización deja los datos preparados para algoritmos que pueden verse afectados por diferencias de escala, aunque su utilidad definitiva dependerá del clasificador seleccionado en las fases posteriores.

4.4 Minería de datos y modelamiento

La etapa de minería de datos corresponde al momento en que se aplicarán algoritmos de Machine Learning para identificar patrones y construir modelos capaces de asignar una especie a partir de las características morfológicas de una flor.

Debido a que `Species` es una variable categorica con tres clases conocidas, el modelamiento futuro deberá considerar algoritmos de clasificación supervisada multiclase. Sin embargo, en esta Fase 1 no se selecciona un algoritmo definitivo, no se divide el dataset en conjuntos de entrenamiento y prueba, ni se calculan métricas de desempeño. Anticipar estas actividades excedería el alcance establecido para el presente avance.

La decisión metodológica adoptada consiste, por tanto, en dejar preparado y documentado el flujo de datos para que en las fases posteriores puedan compararse clasificadores bajo condiciones reproducibles.

4.5 Interpretación y evaluación

En las fases posteriores, la interpretación y evaluación permitirán determinar si los modelos construidos diferencian adecuadamente las tres especies. Esta evaluación deberá considerar métricas apropiadas para clasificación multiclase y analizar los errores cometidos entre las categorías.

En la presente fase, la interpretación se limita a los resultados exploratorios obtenidos mediante estadísticas descriptivas, boxplots, correlaciones y p-valores. Estas evidencias permiten examinar la estructura de los datos y formular expectativas iniciales sobre su capacidad para diferenciar especies, pero no constituyen una evaluación predictiva.

Por lo tanto, todavía no es posible afirmar que el sistema clasificará correctamente nuevas flores. La conclusión válida en esta etapa es que la estructura del dataset y la disponibilidad de una variable objetivo-etiquetada justifican continuar el proyecto mediante un enfoque supervisado de clasificación multiclase.

4.6 Síntesis del flujo KDD



Ilustración 1 Diagrama de flujo KDD. Elaboración propia a partir de Fayyad et al. (1996).

V. Notebook F1_Definición.ipynb

El notebook F1_Definición.ipynb constituye la evidencia técnica de las decisiones conceptuales y metodológicas adoptadas durante la Fase 1. Su propósito no es entrenar ni evaluar modelos, sino representar computacionalmente el problema definido para IrisFlow, caracterizar el conjunto de datos y verificar que su estructura sea coherente con un enfoque de aprendizaje supervisado de clasificación multiclase.

El flujo implementado comprende la carga del dataset Iris, la construcción de una estructura tabular, la inspección de los datos, el análisis descriptivo de las variables, la generación de visualizaciones iniciales, el estudio exploratorio de relaciones y la preparación de las variables para las fases posteriores. De esta manera, el notebook funciona como vínculo entre el problema descrito en el informe y su implementación en un entorno computacional.

5.1 Definición del problema en el notebook

El problema analítico consiste en determinar si las características morfológicas disponibles en el dataset Iris permiten sustentar una futura solución de Machine Learning orientada a clasificar flores en tres especies conocidas: *setosa*, *versicolor* y *virginica*.

Cada observación representa una flor y contiene cuatro variables predictoras numéricas continuas: longitud del sépalo, ancho del sépalo, longitud del pétalo y ancho del pétalo. Además, dispone de la variable objetivo *Species*, que indica la especie correspondiente.

La presencia de una etiqueta conocida para cada observación permite formalizar el problema como una clasificación supervisada multiclase. En esta fase, el notebook se utiliza para comprobar las características de los datos y preparar el flujo de trabajo, sin entrenar todavía un modelo predictivo.

5.2 Objetivo representados en el notebook

El objetivo general del notebook es caracterizar y preparar el conjunto de datos Iris, con el propósito de verificar su pertinencia para un futuro proceso de clasificación supervisada de especies a partir de características morfológicas.

Los objetivos específicos implementados son los siguientes:

- Cargar el dataset Iris y organizarlo en una estructura tabular.
- Identificar las variables predictoras y la variable objetivo.
- Verificar la cantidad de observaciones, los tipos de datos y la existencia de valores faltantes.
- Examinar la distribución de las variables mediante estadísticas descriptivas y visualizaciones.
- Analizar exploratoriamente las relaciones existentes entre las variables.
- Preparar representaciones transformadas de los datos para etapas posteriores.
- Mantener separada la variable objetivo-categorica de las transformaciones aplicadas a las variables predictoras.
- Documentar la correspondencia entre las operaciones ejecutadas y las etapas iniciales de KDD.

Estos objetivos se relacionan directamente con el objetivo general del proyecto, debido a que permiten comprobar si los datos disponibles poseen una estructura adecuada para continuar con el desarrollo de una solución de clasificación.

5.3 Estructura del flujo de trabajo




Ilustración 2 Estructura del flujo de trabajo implementado en el notebook.

Esta estructura sigue una secuencia coherente con las primeras etapas de KDD. Primero se seleccionan los datos relevantes; posteriormente se revisa su estructura y calidad; después se realizan transformaciones destinadas a facilitar el análisis y el futuro modelamiento. El entrenamiento y la evaluación de clasificadores quedan expresamente fuera del alcance de la Fase 1.

5.4 Descripción del código base

El código comienza importando las librerías necesarias para la manipulación de datos, el cálculo numérico, la visualización y la preparación de variables. Se utilizan pandas y numpy para trabajar con los datos; matplotlib y seaborn para generar visualizaciones; y componentes de scikit-learn para cargar el dataset Iris y aplicar normalización.

Posteriormente, el conjunto Iris se carga mediante `load_iris()` y se transforma en un DataFrame denominado `bbdd1`. En esta estructura se incorporan las cuatro características morfológicas como variables predictoras y se agrega `Species` como variable categórica. Esta decisión conserva una representación comprensible de la etiqueta y permite diferenciarla de las variables numéricas utilizadas como entrada.

La estructura y las principales características del conjunto se examinan mediante `info()` y `describe(include="all")`. Estas operaciones permiten revisar la cantidad de observaciones, los tipos de variables, las medidas descriptivas y la completitud general del dataset.

El notebook también genera un boxplot de las variables predictoras. Esta visualización permite comparar sus distribuciones, observar diferencias de escala e identificar posibles valores extremos. Su finalidad es exploratoria y no corresponde todavía a una evaluación predictiva.

A continuación, se crea `bbdd2`, una copia del conjunto original en la cual `Species` se codifica temporalmente con valores numéricos. Esta representación permite reproducir el análisis de correlaciones y p-valores incluido en el material docente. Sin embargo, los valores asignados a las especies no representan magnitudes ni un orden natural; por consiguiente, la correlación con esta codificación debe interpretarse con cautela y no constituye la evidencia principal para seleccionar el tipo de aprendizaje. Después se normalizan las cuatro variables predictoras mediante `MinMaxScaler`, transformando sus valores al intervalo entre 0 y 1. La variable `Species` no se normaliza, debido a que corresponde a una

categoría y no a una medida numérica continua. Finalmente, la etiqueta original se reincorpora a las variables normalizadas, generando una base preparada para las siguientes fases del proyecto.

5.5 Evidencias técnicas obtenidas

La ejecución del notebook permite establecer las siguientes evidencias:

- El dataset contiene 150 observaciones.
- Cada observación posee cuatro variables predictoras numéricas continuas.
- La variable objetivo Species es categórica nominal.
- La variable objetivo contiene tres clases conocidas.
- Cada especie posee 50 observaciones, por lo que el conjunto presenta un balance inicial entre clases.
- No se identifican valores faltantes en las variables analizadas.
- Las variables predictoras presentan diferentes rangos y dispersiones.
- La longitud y el ancho del pétalo muestran una asociación lineal elevada entre sí.
- La normalización modifica la escala de los predictores, pero conserva la información categórica de Species.
- El conjunto queda estructurado para un futuro proceso de clasificación supervisada.

Estas evidencias respaldan la decisión metodológica, pero no demuestran todavía la capacidad predictiva de un modelo. Para determinar dicha capacidad será necesario entrenar y evaluar algoritmos en las fases posteriores.

5.6 Correspondencia entre el notebook y el enfoque seleccionado

Tabla 2 Correspondencia entre la evidencia del notebook y las decisiones metodológicas.

Elemento	Evidencia del notebook	Decisión metodológica
Unidad de análisis	Cada fila corresponde a una flor Iris	Clasificar observaciones individuales
Variables de entrada	Cuatro mediciones morfológicas numéricas	Utilizarlas como predictores
Variable objetivo	Species está disponible para cada observación	Aplicar aprendizaje supervisado
Tipo de objetivo	Variable categórica nominal con tres categorías	Formular una clasificación multiclase
Balance de clases	50 observaciones por especie	No aplicar balanceo en esta fase
Valores faltantes	No se observan registros incompletos	No aplicar imputación
Diferencias de escala	Las variables poseen rangos distintos	Evaluar normalización según el algoritmo
Alcance de la fase	No existe entrenamiento ni evaluación	Reservar el modelamiento para fases posteriores

La decisión de seleccionar aprendizaje supervisado se sustenta principalmente en la existencia de una variable objetivo-conocida. La clasificación multiclase se justifica porque Species puede asumir tres categorías nominales. Por lo tanto, la estructura implementada en el notebook coincide con la definición conceptual expuesta en el informe.

5.7 Decisiones y limitaciones del notebook

Más allá de las evidencias descriptivas presentadas en el apartado anterior, la implementación del notebook implicó decisiones metodológicas puntuales que conviene explicitar, junto con las limitaciones propias del alcance de esta fase:

- Se decidió no dividir el dataset en conjuntos de entrenamiento y prueba, porque en la Fase 1 no se entrena ni evalúa ningún modelo.
- La codificación numérica de Species en bbdd2 se aplicó únicamente como recurso exploratorio para calcular correlaciones y p-valores; no reemplaza la naturaleza categórica de la variable ni se utilizará como entrada de un futuro clasificador.
- Se aplicó MinMaxScaler solo a las cuatro variables predictoras, dejando Species sin normalizar, dado que normalizar una variable categórica carece de sentido estadístico.
- No se realizó tratamiento de valores faltantes ni de outliers más allá de su identificación visual mediante el boxplot, porque el dataset no presentó nulos y el tratamiento de valores extremos corresponde a fases posteriores de modelamiento.
- La matriz de correlación y de p-valores se calculó sobre bbdd2 con fines exploratorios; no se utiliza como criterio de selección de variables en esta fase, ya que esa decisión corresponde al proceso de modelamiento en F2.
- Una limitación relevante es que el balance de clases (50 observaciones por especie) corresponde a este dataset específico y no garantiza que datos futuros mantengan la misma proporción.
- Otra limitación es que las visualizaciones y estadísticas descriptivas permiten formular expectativas sobre la separabilidad de las especies, pero no constituyen evidencia predictiva ni sustituyen una validación con métricas de clasificación.
- El notebook no contempla todavía la selección de un algoritmo específico de clasificación; esa comparación se abordará entre distintos clasificadores en la Fase 2.
- Estas decisiones se documentan para mantener trazabilidad entre lo ejecutado en el notebook y lo justificado conceptualmente en el informe.
- El alcance definido para esta fase no permite anticipar métricas de desempeño, matrices de confusión ni resultados de clasificación, ya que estos dependen del entrenamiento de un modelo aún no realizado.

En conjunto, estas decisiones y limitaciones delimitan con precisión lo que la Fase 1 puede afirmar: que la estructura de los datos es compatible con un enfoque supervisado de clasificación multiclase, sin que ello implique todavía una capacidad predictiva demostrada.

5.8 Síntesis del notebook

El notebook proporciona una implementación inicial coherente con el problema de IrisFlow. La carga y caracterización del dataset permiten identificar la estructura de las variables; la revisión de calidad confirma que los datos se encuentran completos y balanceados; y las transformaciones generan una base preparada para el trabajo posterior.

En consecuencia, el notebook no pretende demostrar que un clasificador ya funciona, sino documentar que los datos y el objetivo analítico son compatibles con una futura solución de aprendizaje supervisado de clasificación multiclase. Esta delimitación mantiene la coherencia entre el informe, la implementación y el alcance de la Fase 1.

VI. Comparación de enfoques y justificación del descarte

La selección de un enfoque de Machine Learning debe responder a la naturaleza del problema, la estructura de los datos y el objetivo analítico. En IrisFlow, el propósito consiste en asignar una especie conocida a cada flor a partir de cuatro características morfológicas. Además, el dataset contiene la etiqueta Species para las 150 observaciones.

Estas condiciones orientan el proyecto hacia un enfoque de aprendizaje supervisado de clasificación multiclase. No obstante, antes de adoptar esta decisión se consideraron enfoques alternativos: regresión supervisada, aprendizaje no supervisado y aprendizaje por refuerzo.

6.1 Enfoque seleccionado: clasificación supervisada multiclase

La clasificación supervisada multiclase se selecciona porque el dataset Iris satisface simultáneamente las dos condiciones que definen este enfoque: cada observación dispone de una etiqueta previamente conocida (Species) y dicha etiqueta corresponde a una de tres categorías discretas (setosa, versicolor, virginica), sin relación de orden ni magnitud entre ellas.

Bajo este enfoque, un futuro modelo aprenderá, a partir de ejemplos ya etiquetados, la relación entre las cuatro variables morfológicas de entrada y la especie correspondiente, para luego generalizar esa relación a observaciones nuevas cuya especie se desconozca.

Esta decisión aprovecha la totalidad de la información disponible en el dataset —incluida la etiqueta Species— en lugar de descartarla, y responde de manera directa a la pregunta analítica planteada para IrisFlow: determinar si las características morfológicas permiten diferenciar las tres especies mediante un enfoque supervisado.

La cadena lógica que sustenta esta selección se resume en la Ilustración 3: datos etiquetados, variable objetivo categórica con tres clases y un propósito de asignación de categoría son condiciones que, en conjunto, determinan la clasificación supervisada multiclase como enfoque principal del proyecto.




Ilustración 3 Cadena lógica para la selección de la clasificación supervisada multiclase.

6.2 Alternativa 1: regresión supervisada

La regresión también pertenece al aprendizaje supervisado, pero se utiliza cuando la variable objetivo es numérica continua. Por ejemplo, podría aplicarse si el propósito fuera predecir la longitud del pétalo o alguna otra medida cuantitativa.

Este enfoque se descarta para el objetivo principal de IrisFlow porque Species no representa una magnitud medible. Los valores *setosa*, *versicolor* y *virginica* son categorías nominales, sin distancia cuantitativa ni orden natural entre ellas.

Convertir estas categorías en valores como 1, 2 y 3 no transforma el problema en una regresión. Esa codificación se utiliza en el notebook únicamente como apoyo para ciertos análisis exploratorios. Interpretar dichos números como una variable continua produciría resultados conceptualmente incorrectos.

Por lo tanto, la regresión no responde a la pregunta analítica del proyecto y se descarta como enfoque principal.

6.3 Alternativa 2: aprendizaje no supervisado

El aprendizaje no supervisado se utiliza cuando los datos no cuentan con una variable objetivo conocida y se busca descubrir estructuras internas, agrupamientos o patrones de similitud. En el caso de Iris, podría aplicarse un algoritmo de *clustering* para explorar si las flores forman grupos a partir de sus características morfológicas.

Sin embargo, el dataset ya contiene la especie correspondiente a cada observación y el objetivo del proyecto consiste en predecir esas categorías conocidas. Utilizar solamente un enfoque no supervisado implicaría ignorar información disponible que resulta directamente pertinente para el problema.

Además, los grupos obtenidos mediante *clustering* no necesariamente coincidirían con las especies reales, ya que los algoritmos no supervisados agrupan observaciones según criterios de similitud y no según etiquetas conocidas.

En consecuencia, el aprendizaje no supervisado se descarta como enfoque principal. No obstante, podría utilizarse en una fase posterior como análisis exploratorio complementario para comparar los agrupamientos naturales con las especies registradas.

6.4 Alternativa 3: aprendizaje por refuerzo

El aprendizaje por refuerzo se aplica en problemas donde un agente interactúa de manera secuencial con un entorno, ejecuta acciones y recibe recompensas o penalizaciones. Su objetivo es aprender una estrategia que maximice la recompensa acumulada.

La estructura del proyecto IrisFlow no presenta estas condiciones. El dataset es estático, cada observación corresponde a una flor independiente y no existe un agente que deba tomar decisiones sucesivas. Tampoco se dispone de un entorno dinámico ni de una función de recompensa.

Por estas razones, el aprendizaje por refuerzo no es compatible con la naturaleza de los datos ni con el

objetivo analítico y se descarta para el proyecto.

6.5 Comparación de los enfoques

Tabla 3 Comparación de los enfoques de aprendizaje considerados para IrisFlow.

Enfoque	Requisito principal	Aplicación posible	Relación con IrisFlow	Decisión
Clasificación supervisada	Datos etiquetados y objetivo categórico	Predecir una categoría conocida	Especies está disponible para cada observación y contiene tres clases	Seleccionado
Regresión supervisada	Objetivo numérico continuo	Predecir una magnitud	Especies no es una cantidad ni posee escala numérica	Descartado
Aprendizaje no supervisado	Datos sin etiqueta o búsqueda de estructuras ocultas	Descubrir agrupamientos	Podría explorar grupos, pero no aprovecha las etiquetas disponibles	Descartado como enfoque principal
Aprendizaje por refuerzo	Agente, entorno, acciones y recompensas	Optimizar decisiones secuenciales	El dataset es estático y no existe interacción ni recompensa	Descartado

6.6 Justificación de la decisión adoptada

La clasificación supervisada multiclase es el enfoque que presenta mayor coherencia con IrisFlow, porque aprovecha la totalidad de la información disponible y responde directamente al objetivo de asignar una especie a partir de características morfológicas.

La decisión no depende de que un algoritmo haya obtenido buenos resultados, puesto que en esta fase todavía no se entrenan modelos. Se fundamenta en tres condiciones verificables:

- Cada observación dispone de una etiqueta conocida.
- La variable objetivo es categórica nominal.
- El resultado esperado corresponde a una de tres clases.

La regresión se descarta porque requiere una variable objetivo continua; el aprendizaje no supervisado, porque no aprovecha directamente las etiquetas disponibles; y el aprendizaje por refuerzo, porque no existe interacción secuencial con un entorno.

En consecuencia, la clasificación supervisada multiclase constituye la decisión metodológica más adecuada para orientar las fases posteriores. Más adelante será necesario comparar algoritmos específicos de clasificación y evaluar su desempeño, pero esa decisión no forma parte del alcance de la Fase 1.

VII. Documentación del proceso

Este apartado documenta el proceso de toma de decisiones técnicas adoptadas durante la Fase 1, así como los ajustes realizados sobre la propuesta inicial, con el propósito de mantener trazabilidad entre el problema definido, la implementación en el notebook y el repositorio del proyecto.

7.1 Decisiones técnicas

La primera decisión técnica consistió en utilizar el dataset Iris disponible en scikit-learn (`sklearn.datasets.load_iris`) en lugar de una fuente externa, debido a que se trata de un conjunto de acceso público que no requiere configuración adicional, asegurando la reproducibilidad del notebook. La segunda decisión consistió en conservar la variable *Species* como categórica en el DataFrame principal (`bbdd1`) y generar una copia numérica (`bbdd2`) exclusivamente para el análisis exploratorio de correlaciones, evitando interpretar las categorías como una escala continua. La tercera decisión consistió en aplicar `MinMaxScaler` únicamente a las cuatro variables predictoras, dejando la variable objetivo sin transformar.

7.2 Relación entre decisiones y enfoque

Cada una de las decisiones técnicas descritas responde directamente al enfoque de clasificación supervisada multiclase seleccionado: usar un dataset con etiqueta conocida y de acceso público, preservar la naturaleza categórica de *Species*, y preparar únicamente los predictores para un futuro entrenamiento son acciones coherentes con un problema que, en fases posteriores, requerirá dividir los datos en conjuntos de entrenamiento y prueba, y entrenar clasificadores capaces de asignar una especie a partir de las variables morfológicas.

VIII. Conclusiones

8.1 Síntesis de decisiones

El desarrollo de esta primera fase permitió establecer que el dataset Iris, compuesto por 150 observaciones balanceadas en tres especies y sin valores faltantes, es compatible con un enfoque de aprendizaje supervisado de clasificación multiclase. Esta decisión se sustenta en la disponibilidad de una variable objetivo conocida (*Species*) y en su naturaleza categórica nominal, condiciones verificadas tanto

en el análisis documental como en la exploración computacional realizada en el notebook.

8.2 Relación con KDD

Las actividades desarrolladas en esta fase corresponden a las etapas iniciales del proceso KDD: selección del dataset, preprocesamiento mediante la revisión de estructura y calidad, y transformación a través de la normalización de los predictores. Estas etapas constituyen la base sobre la cual se aplicará, en fases posteriores, la minería de datos mediante algoritmos de clasificación supervisada y, finalmente, la interpretación y evaluación de los resultados obtenidos.

8.3 Proyección del enfoque


En las fases siguientes del proyecto (F2–F4) corresponderá dividir el conjunto de datos en entrenamiento y prueba, entrenar distintos algoritmos de clasificación supervisada multiclase (por ejemplo, regresión logística, árboles de decisión o k-NN) y evaluar su desempeño mediante métricas como exactitud y matriz de confusión. La base conceptual y técnica establecida en esta Fase 1 —el problema definido, el enfoque justificado y los datos preparados— permite avanzar hacia estas etapas con una ruta metodológica reproducible y documentada.

IX. Uso de fuentes, citación y referencias


- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54. <https://doi.org/10.1609/aimag.v17i3.1230>[cite: 1, 2]
- Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188. <https://doi.org/10.1111/j.1469-1809.1936.tb02137.x>[cite: 1, 2]
- Ruete, M. (2026a). *Guía de Orientación Metodológica - Fase 1: Definición y orientación de la situación* [Material de clase]. Magíster en Ciencia de Datos e Inteligencia Artificial, Universidad Andrés Bello.[cite: 1, 2]
- Ruete, M. (2026b). *Documento de Requerimientos y Estructura del Informe ABP - MCDI504 Machine Learning I* [Material de clase]. Magíster en Ciencia de Datos e Inteligencia Artificial, Universidad Andrés Bello.[cite: 1, 2]
- Ruete, M. (2026c). *Notebook de Exploración y Preprocesamiento de Datos - Proyecto IrisFlow* [Código fuente]. Magíster en Ciencia de Datos e Inteligencia Artificial, Universidad Andrés Bello.[cite: 1, 3]
- Scikit-learn developers. (s. f.). *Iris plants dataset*. Scikit-learn: Machine Learning in Python. Recuperado de https://scikit-learn.org/stable/datasets/toy_dataset.html#iris-plants-dataset[cite: 1, 3, 4]

X. Anexos


Se incluyen a continuación las visualizaciones generadas en el notebook F1_Definición.ipynb, que respaldan el análisis descriptivo y exploratorio presentado en las secciones anteriores del informe.



Anexo 1. Boxplot de las variables predictoras del dataset Iris. Fuente: notebook F1_Definición.ipynb.



Anexo 2. Matriz de correlación de Pearson entre las variables del dataset Iris (bddd2). Fuente: notebook F1_Definición.ipynb.



Anexo 3. Matriz de p-valores asociados a la correlación de Pearson. Fuente: notebook F1_Definición.ipynb.