

MCDI504

MACHINE LEARNING I

**AVANCE DEL PROYECTO — FASE 2:
BÚSQUEDA Y RECOPIACIÓN DE
INFORMACIÓN**

Nombre integrante/s:

Fabian Castillo
Francisco Santelices
Renato Villazón

Curso:

MCDI504 – Machine Learning I

Fecha:

13 de agosto de 2026

APARTADOS

II. Introducción y contextualización	3
2.1 Objetivo analítico	3
2.2 Continuidad metodológica con la Fase 1	3
III. Descripción del conjunto de datos y preprocesamiento	3
3.1 Descripción general del conjunto de datos	3
3.2 Revisión de calidad y definición de X e y	4
3.3 Partición de entrenamiento y prueba	4
3.4 Estandarización de los predictores	4
IV. Modelo de regresión lineal	5
4.1 Configuración e implementación	5
4.2 Interpretación	5
V. Modelo de árbol de decisión para regresión	5
5.1 Configuración e implementación	5
5.2 Interpretación	6
VI. Modelo de red neuronal MLP para regresión	6
6.1 Configuración e implementación	6
6.2 Interpretación	7
VII. Evaluación de modelos de regresión	7
VIII. Comparación y selección de modelos	7
IX. Notebook F2_Regresion.ipynb y documentación del proceso	8
9.1 Decisiones, cambios y reproducibilidad	8
9.2 Estructura del repositorio	8
X. Conclusiones	8
XI. Uso de fuentes, citación y referencias	9
XII. Anexos	9
Anexo. Resultados principales de la ejecución	9

II. Introducción y contextualización

La Fase 2 aborda un problema de predicción asociado al conjunto California Housing, compuesto por información demográfica, habitacional y geográfica de distritos censales de California. Cada observación reúne ocho variables predictoras y un valor conocido de MedHouseVal, que representa el valor mediano de las viviendas expresado en cientos de miles de dólares. Esta estructura permite estudiar cómo las características disponibles se relacionan con una magnitud económica continua (Pace & Barry, 1997; scikit-learn developers, s. f.).

La situación que origina el análisis es la necesidad de estimar el valor mediano de las viviendas para observaciones no utilizadas durante el entrenamiento. Desde la perspectiva de ciencia de datos, la tarea consiste en aprender una función que relacione los predictores con MedHouseVal y que sea capaz de generalizar a nuevos registros. Como la variable objetivo es numérica continua y se encuentra observada en el dataset, el problema corresponde a aprendizaje supervisado de regresión y no a clasificación.

2.1 Objetivo analítico

El objetivo de esta fase es implementar y comparar tres modelos de regresión supervisada —regresión lineal, árbol de decisión y red neuronal perceptrón multicapa (MLP)— para determinar cuál presenta el mejor desempeño predictivo sobre el conjunto de prueba. La comparación se realizará mediante el error cuadrático medio (MSE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2), utilizando el RMSE como criterio principal por expresar el error típico en la misma escala de la variable objetivo.

2.2 Continuidad metodológica con la Fase 1

La Fase 1 estableció la lógica para clasificar un problema de Machine Learning según la naturaleza de los datos, la variable objetivo y el propósito analítico. En aquella etapa, IrisFlow correspondía a clasificación multiclase porque Species era categórica. La presente fase aplica el mismo criterio de decisión a un nuevo escenario pedagógico: MedHouseVal es continua y el propósito es estimar una magnitud, por lo que se seleccionan modelos de regresión. La continuidad se encuentra en el proceso metodológico —definir el problema, preparar los datos, implementar, evaluar y justificar decisiones— y no en la identidad del dataset ni en el tipo de salida.

En consecuencia, los datos, el objetivo y los modelos mantienen una relación directa: las ocho variables del dataset funcionan como predictores; MedHouseVal constituye la respuesta continua; y los tres algoritmos representan alternativas con distintos niveles de complejidad e interpretabilidad. La regresión lineal se utilizará como línea base, el árbol permitirá capturar relaciones no lineales mediante particiones y el MLP permitirá representar patrones más complejos. Su selección final se fundamentará en evidencia obtenida sobre datos de prueba y no solamente en las características teóricas de cada modelo.

III. Descripción del conjunto de datos y preprocesamiento

3.1 Descripción general del conjunto de datos

El conjunto California Housing contiene 20.640 observaciones correspondientes a distritos censales de California y nueve columnas en la base analítica: ocho variables predictoras numéricas y la variable objetivo MedHouseVal. Los predictores describen condiciones económicas, habitacionales, demográficas y geográficas. La unidad de análisis es el distrito censal y no una vivienda individual, por lo que cada valor resume características del conjunto de viviendas perteneciente al distrito (Pace & Barry, 1997; scikit-learn developers, s. f.).

Tabla 1. Variables utilizadas en el modelamiento

Variable	Rol	Descripción
MedInc	Predictora	Ingreso mediano del distrito.
HouseAge	Predictora	Edad mediana de las viviendas.
AveRooms	Predictora	Promedio de habitaciones por hogar.
AveBedrms	Predictora	Promedio de dormitorios por hogar.
Population	Predictora	Población del distrito censal.
AveOccup	Predictora	Promedio de ocupantes por hogar.
Latitude	Predictora	Coordenada geográfica de latitud.
Longitude	Predictora	Coordenada geográfica de longitud.
MedHouseVal	Objetivo	Valor mediano de viviendas, en cientos de miles de dólares.

Nota. Elaboración propia a partir de la descripción oficial de California Housing.

3.2 Revisión de calidad y definición de X e y

La inspección inicial confirmó una matriz de 20.640 filas y nueve columnas, sin valores faltantes en la base analítica utilizada. Cuando la descarga oficial de scikit-learn no se encuentra disponible, el notebook emplea una copia pública de respaldo y documenta la imputación mediana de total_bedrooms antes de construir AveBedrms. Esta alternativa evita que una restricción temporal del servidor impida reproducir el flujo, pero mantiene explícita la transformación aplicada.

A continuación, se separó la información en X e y. X contiene las ocho variables predictoras y posee dimensión (20.640, 8), mientras que y contiene exclusivamente MedHouseVal y posee dimensión (20.640,). Esta separación formaliza el aprendizaje supervisado: los modelos reciben los predictores y aprenden a aproximar el valor objetivo observado.

3.3 Partición de entrenamiento y prueba

Los datos se dividieron mediante train_test_split, asignando el 80 % al entrenamiento y el 20 % a la prueba. La semilla random_state=42 permite reproducir exactamente la partición. De este modo, 16.512 observaciones se utilizan para ajustar los modelos y 4.128 permanecen reservadas para evaluar su capacidad de generalización. El conjunto de prueba no participa en el entrenamiento ni en el ajuste del escalador.

3.4 Estandarización de los predictores

Las variables predictoras presentan unidades y rangos diferentes, por lo que se aplicó StandardScaler. El escalador se ajustó exclusivamente con X_train y después se utilizó para transformar X_train y X_test. Esta decisión evita fuga de información, ya que las medias y desviaciones del conjunto de prueba no influyen en el preprocesamiento. El escalamiento es especialmente relevante para la optimización del MLP; se conserva también para la regresión lineal y el árbol con el fin de mantener una entrada común y comparable.

Tabla 2. Evidencia y justificación del preprocesamiento

Etapas	Resultado	Decisión metodológica
Base analítica	20.640 × 9; sin nulos	Utilizar los registros disponibles.
Predictores X	(20.640, 8)	Excluir MedHouseVal de las entradas.
Objetivo y	(20.640,)	Predecir una variable continua.
Entrenamiento	16.512 observaciones	Ajustar modelos con el 80 %.

Etapa	Resultado	Decisión metodológica
Prueba	4.128 observaciones	Evaluar generalización con el 20 %.
Semilla	random_state=42	Asegurar reproducibilidad.
Escalamiento	StandardScaler	Ajustar solo con X_train para evitar fuga.

Nota. Resultados obtenidos mediante la ejecución de F2_Regresion.ipynb.

El preprocesamiento establece una base común para los tres modelos y permite que sus métricas sean comparables. Las decisiones adoptadas —separación de roles, partición reproducible y escalamiento sin acceso al conjunto de prueba— buscan que las diferencias de desempeño se asocien principalmente con la capacidad de cada algoritmo y no con tratamientos distintos de los datos.

IV. Modelo de regresión lineal

4.1 Configuración e implementación

La regresión lineal se implementó mediante LinearRegression de scikit-learn y se utilizó como línea base por su simplicidad, estabilidad e interpretabilidad. El modelo fue entrenado con X_train_scaled y y_train, y posteriormente generó predicciones sobre X_test_scaled. Al utilizar las ocho variables predictoras, la implementación corresponde técnicamente a una regresión lineal múltiple, aunque el formato de la actividad la denomine regresión lineal simple (Ruete, 2026a; scikit-learn Developers, 2026a).

El algoritmo estima un intercepto y un coeficiente para cada predictor, minimizando la suma de errores cuadrados. Como los predictores fueron estandarizados, los coeficientes permiten comparar la dirección e intensidad relativa de las asociaciones, pero no representan cambios expresados directamente en las unidades originales.

Tabla 3. Resultados del modelo de regresión lineal

Métrica	Valor	Interpretación
MSE	0,7254	Promedio de errores cuadrados.
RMSE	0,8517	Error típico en la escala de MedHouseVal.
R ²	0,4464	Explica aproximadamente 44,64 % de la variabilidad.

Nota. Resultados obtenidos sobre 4.128 observaciones de prueba en F2_Regresion.ipynb.

4.2 Interpretación

El RMSE de 0,8517 equivale aproximadamente a 85.170 dólares, debido a que MedHouseVal está expresada en cientos de miles de dólares. El R² de 0,4464 indica que el modelo explica alrededor del 44,64 % de la variabilidad del valor mediano de las viviendas en la partición de prueba. El resultado confirma su utilidad como referencia interpretable, pero también sugiere que una relación estrictamente lineal no captura toda la complejidad de los datos.

V. Modelo de árbol de decisión para regresión

5.1 Configuración e implementación

El segundo modelo se implementó con DecisionTreeRegressor. A diferencia de la regresión lineal, el árbol divide recursivamente el espacio de predictores y asigna a cada región una predicción constante. Esta estructura permite representar umbrales, interacciones y relaciones no lineales sin imponer una forma funcional previa (Ruete, 2026b; scikit-learn Developers, 2026c).

Tabla 4. Configuración del árbol de decisión

Parámetro	Valor	Justificación
max_depth	5	Limitar complejidad y reducir sobreajuste.
random_state	42	Reproducir el ajuste.
Entrada	X_train_scaled	Mantener una entrada común entre modelos.
Objetivo	MedHouseVal	Predecir una respuesta continua.

Nota. Configuración utilizada en F2_Regresion.ipynb.

Tabla 5. Resultados del árbol de decisión

Métrica	Valor	Interpretación
MSE	0,5245	Menor error cuadrático que la línea base.
RMSE	0,7242	Error típico aproximado de 72.420 dólares.
R ²	0,5997	Explica aproximadamente 59,97 % de la variabilidad.

Nota. Resultados obtenidos sobre el mismo conjunto de prueba.

5.2 Interpretación

El árbol mejora las tres métricas respecto de la regresión lineal. La reducción del RMSE desde 0,8517 hasta 0,7242 y el aumento de R² hasta 0,5997 indican que los umbrales y relaciones no lineales aportan capacidad predictiva. La profundidad limitada controla parcialmente el sobreajuste; sin embargo, una evaluación más concluyente requeriría comparar errores de entrenamiento y validación mediante validación cruzada.

VI. Modelo de red neuronal MLP para regresión

6.1 Configuración e implementación

El tercer modelo corresponde a MLPRegressor, una red neuronal de propagación hacia adelante capaz de aprender funciones no lineales mediante capas de neuronas interconectadas. Los predictores estandarizados son necesarios para estabilizar la optimización y evitar que variables con escalas mayores dominen la actualización de pesos (Ruete, 2026c; scikit-learn Developers, 2026d).

Tabla 6. Configuración de la red neuronal MLP

Hiperparámetro	Valor	Justificación
hidden_layer_sizes	(100,)	Una capa oculta con 100 neuronas.
activation	relu	Representar relaciones no lineales.
solver	adam	Optimización adaptativa.
max_iter	500	Límite máximo de iteraciones.
early_stopping	True	Detener el ajuste si no mejora validación.
random_state	42	Asegurar reproducibilidad.

Nota. Configuración inicial proporcionada y ejecutada en el notebook.

Tabla 7. Resultados de la red neuronal MLP

Métrica	Valor	Interpretación
MSE	0,3343	Menor error cuadrático de los tres modelos.
RMSE	0,5782	Error típico aproximado de 57.820 dólares.
R ²	0,7449	Explica aproximadamente 74,49 % de la variabilidad.

Nota. Resultados obtenidos sobre el conjunto de prueba.

6.2 Interpretación

El MLP logra el mejor desempeño de la comparación inicial. Su RMSE es 0,2735 inferior al de la regresión lineal y 0,1460 inferior al del árbol. Asimismo, su R^2 alcanza 0,7449. Estos resultados sugieren que la relación entre los predictores y MedHouseVal contiene patrones complejos que una arquitectura no lineal puede representar mejor. La ventaja predictiva debe ponderarse con su menor interpretabilidad y con la necesidad de validar la estabilidad del resultado.

VII. Evaluación de modelos de regresión


Los tres modelos se evaluaron sobre las mismas 4.128 observaciones de prueba. El MSE penaliza con mayor intensidad los errores grandes; el RMSE expresa el error típico en la escala de MedHouseVal; y R^2 mide la proporción de variabilidad explicada. Para seleccionar preliminarmente el modelo se utiliza el menor RMSE como criterio principal y MSE y R^2 como evidencia complementaria (Ruete, 2026d).

Tabla 8. Comparación de métricas en el conjunto de prueba

Modelo	MSE	RMSE	R^2
Regresión lineal	0,7254	0,8517	0,4464
Árbol de decisión	0,5245	0,7242	0,5997
Red neuronal MLP	0,3343	0,5782	0,7449

Nota. Resultados de la ejecución reproducible con random_state=42.

Figura 1. Comparación gráfica de MSE, RMSE y R^2



Nota. Elaboración propia a partir de F2_Regresion.ipynb.

VIII. Comparación y selección de modelos

Tabla 9. Ventajas, limitaciones y decisión analítica

Modelo	Ventaja principal	Limitación	Decisión
Regresión lineal	Alta interpretabilidad.	No captura bien relaciones no lineales.	Mantener como línea base.
Árbol	Reglas y umbrales comprensibles.	Puede sobreajustar y predice por regiones.	Alternativa intermedia.
MLP	Mejor desempeño y alta flexibilidad.	Menor interpretabilidad.	Seleccionado preliminarmente.

Nota. La selección considera desempeño y no elimina la utilidad analítica de los modelos restantes.

La red neuronal MLP se selecciona preliminarmente porque obtiene simultáneamente el menor MSE, el menor RMSE y el mayor R^2 . No obstante, esta elección se limita a una partición de prueba y a configuraciones iniciales. La regresión lineal conserva valor como referencia interpretable y el árbol puede facilitar reglas de decisión. Antes de una aplicación real deben incorporarse validación cruzada, ajuste de

hiperparámetros, análisis de residuos y revisión de posibles sesgos geográficos o socioeconómicos.

IX. Notebook F2_Regresion.ipynb y documentación del proceso

El notebook integra narrativa, código, salidas y visualizaciones en un flujo reproducible. Cada etapa del informe se vincula con una evidencia computacional: carga y calidad de datos, definición de X e y, partición, escalamiento, ajuste de modelos, predicciones, métricas y comparación. Todas las celdas fueron ejecutadas consecutivamente y no presentan errores guardados.

Tabla 10. Trazabilidad entre notebook, informe y repositorio

Etapa	Evidencia del notebook	Sección del informe
Datos	Dimensión, primeras filas y nulos.	III
Preprocesamiento	X/y, train/test y StandardScaler.	III
Regresión lineal	Predicciones, MSE, RMSE y R^2 .	IV
Árbol	Parámetros, predicciones y métricas.	V
MLP	Arquitectura, entrenamiento y métricas.	VI
Comparación	Tabla, gráficos y selección.	VII-VIII

Nota. Correspondencia definida a partir de la última ejecución del notebook.

9.1 Decisiones, cambios y reproducibilidad

Las principales decisiones técnicas fueron usar una partición 80/20 reproducible, ajustar StandardScaler solo con entrenamiento, mantener un pipeline común y evaluar sobre el mismo conjunto de prueba. Además, se añadió RMSE al código original porque la rúbrica exige esta métrica. Se reemplazaron interpretaciones hipotéticas por resultados reales y se incorporó una ruta de respaldo documentada para el dataset cuando el servidor oficial rechaza temporalmente la descarga.

9.2 Estructura del repositorio

Tabla 11. Estructura propuesta para la Fase 2

Ruta	Contenido
/notebooks/F1_Definicion.ipynb	Evidencia de la Fase 1.
/notebooks/F2_Regresion.ipynb	Código, narrativa y resultados de Fase 2.
/docs/MCDI504_S1_1_GRUPO5.pdf	Informe final de Fase 1.
/docs/MCDI504_S2_2_GRUPO5.pdf	Informe final de Fase 2.
README.md	Descripción, ejecución y dependencias.
requirements.txt	Librerías necesarias.

Nota. La estructura preserva la continuidad y trazabilidad entre fases.

X. Conclusiones

La Fase 2 permitió implementar y comparar tres modelos de regresión supervisada sobre California Housing. La preparación de los datos estableció una partición reproducible y evitó fuga de información al ajustar el escalador exclusivamente con entrenamiento. Esta base común permitió atribuir las diferencias de métricas principalmente a la capacidad de los algoritmos evaluados.

La regresión lineal obtuvo $RMSE=0,8517$ y $R^2=0,4464$, por lo que funciona como línea base interpretable, aunque presenta capacidad limitada para representar la complejidad del problema. El árbol mejoró a $RMSE=0,7242$ y $R^2=0,5997$, mostrando que las relaciones no lineales aportan información predictiva. El MLP alcanzó $RMSE=0,5782$ y $R^2=0,7449$, constituyéndose en el modelo preliminarmente seleccionado.

La selección del MLP no representa una conclusión definitiva ni implica que sea adecuado para despliegue. El resultado proviene de una única partición y de una configuración inicial. La continuidad del proyecto debe incorporar validación cruzada, ajuste de hiperparámetros, análisis de residuos, comparación de errores entre entrenamiento y validación, evaluación de importancia de variables y consideración de modelos adicionales. También resulta necesario analizar las consecuencias éticas de utilizar variables geográficas y socioeconómicas en decisiones relacionadas con vivienda.

XI. Uso de fuentes, citación y referencias

Las decisiones conceptuales y técnicas se fundamentaron en material docente, documentación oficial y bibliografía académica. Las referencias se presentan en formato APA 7 y mantienen correspondencia con las citas incorporadas en el informe.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An introduction to statistical learning: With applications in Python. Springer. <https://doi.org/10.1007/978-3-031-38747-0>

Pace, R. K., & Barry, R. (1997). Sparse spatial autoregressions. *Statistics & Probability Letters*, 33(3), 291–297. [https://doi.org/10.1016/S0167-7152\(96\)00140-X](https://doi.org/10.1016/S0167-7152(96)00140-X)

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>

Ruete, D. (2026a). Regresión lineal simple, polinomial y multivariable [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026b). Regresión con árboles de decisión [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026c). Regresión con redes neuronales artificiales [Apunte]. Universidad Andrés Bello.

Ruete, D. (2026d). Evaluación de modelos de regresión [Apunte]. Universidad Andrés Bello.

scikit-learn Developers. (2026a). LinearRegression. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

scikit-learn Developers. (2026b). California housing dataset. https://scikit-learn.org/stable/datasets/real_world.html#california-housing-dataset

scikit-learn Developers. (2026c). DecisionTreeRegressor. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html>

scikit-learn Developers. (2026d). MLPRegressor. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPRegressor.html

XII. Anexos

Anexo. Resultados principales de la ejecución

Modelo	MSE	RMSE	R ²
Regresión lineal	0,7254	0,8517	0,4464
Árbol de decisión	0,5245	0,7242	0,5997
Red neuronal MLP	0,3343	0,5782	0,7449